

Mini Cahier des Charges

Projet : Module KYC Automatisé (Vérification de CNI) - Intégration Web Cloud

1. Présentation du Projet

Ce projet consiste à concevoir et déployer un module de vérification d'identité (KYC) automatisé. L'objectif est de permettre à une application en ligne de valider la conformité des Cartes Nationales d'Identité (CNI) téléversées par les utilisateurs en analysant leur structure visuelle, la cohérence des données textuelles et l'authenticité mathématique des bandes MRZ.

2. Spécifications Fonctionnelles

Flux Utilisateur (Frontend)

- Interface de dépôt (Drag & Drop) acceptant les formats `JPG`, `PNG` et `PDF`.
- Indicateur de chargement et de traitement en temps réel.
- Affichage du rapport de conformité :
 - Statut global (Validé / Suspect / Rejeté).
 - Score de confiance globale (en %).
 - Détails des points de contrôle (Format, MRZ, OCR).

Moteur d'Analyse Évolutif (Backend / Worker)

- **Étape 1 : Redressement (Alignment)** : Recadrage automatique de la pièce d'identité via détection de contours ou points clés (ORB/SIFT), correction de l'angle d'inclinaison.
- **Étape 2 : Extraction MRZ** : Localisation de la zone de lecture optique (bas du document) et parsing des caractères.
- **Étape 3 : Validation Mathématique** : Calcul et vérification automatique des clés de contrôle de la ligne MRZ (calcul modulo 10).
- **Étape 4 : Extraction Textuelle (OCR)** : Lecture des champs standards (Nom, Prénom, Date de Naissance) pour validation croisée (Cross-checking) avec la MRZ.

3. Architecture & Stack Technique

Pour concilier la puissance de traitement d'images en local au cours du développement et le déploiement sur une application web en ligne, l'architecture recommandée sépare le frontend de l'API de traitement.

Composant	Technologie Spécifiée	Rôle / Justification
Frontend Client	React / Next.js TypeScript + Tailwind CSS	Interface utilisateur moderne, réactive et typée de façon stricte pour la gestion des fichiers.
API Backend principal	Node.js (NestJS ou Express) OU FastAPI	Gestion des utilisateurs, sécurisation des uploads, passerelle vers le moteur de traitement.
Moteur d'Analyse Image	Python 3.11+ FastAPI	Expose le pipeline de vision. Idéal pour manipuler les données binaires et interagir avec l'écosystème IA/Data.
Traitement d'Image & Alignement	OpenCV (cv2) + Pillow	Prétraitement, filtrage, détection de contours et redressement géométrique des documents.
Moteur OCR	EasyOCR ou Tesseract OCR	Extraction du texte des zones spécifiques et lecture brute de la bande MRZ.
Validation MRZ	mrz (Librairie Python)	Algorithmes de parsing natifs conformes aux normes OACI (ICAO Doc 9303) pour cartes d'identité.

4. Contraintes de Déploiement En Ligne

Gestion des Dépendances Lourdes

Les outils de traitement d'images et d'OCR (notamment Tesseract ou les modèles de Deep Learning d'EasyOCR) nécessitent des binaires système et des fichiers de modèles lourds. Le déploiement doit obligatoirement reposer sur une conteneurisation **Docker** afin de garantir un comportement identique entre l'environnement de développement local et le serveur en ligne.

Infrastructure Web

- **Option Serveur Dédié / VPS (Recommandé)** : Une instance (ex. OVH, AWS EC2, DigitalOcean) disposant d'au moins 2 Go à 4 Go de RAM pour charger les modèles OCR en mémoire sans crash (OOM Killer).
- **Hébergement Docker** : Configuration d'un pipeline CI/CD poussant l'image Docker du moteur Python vers un service capable de faire tourner des conteneurs (Render, Railway, ou une instance VPS autonome).

Important concernant la Sécurité & RGPD : En production, aucune pièce d'identité ne doit être stockée de façon permanente sur le disque sans chiffrement lourd. Le traitement doit idéalement se faire "in-memory" (dans la mémoire vive), et les images de test doivent être immédiatement purgées après analyse.

5. Critères d'Acceptation & Validation

1. **Taux d'alignement réussi** : > 90% sur les images correctement éclairées et cadrées à la volée.
2. **Précision MRZ** : Détection stricte et sans erreur des clés de contrôle sur un document authentique non altéré.
3. **Temps de réponse global** : Analyse complète et retour de l'API en moins de 3.5 secondes par document.